

RECUPERACIÓN DE INFORMACIÓN – GEI - 2026

Prácticas

Information Retrieval Lab

Departamento de Ciencias de la Computación y Tecnologías de la Información.

Objetivo

El objetivo de las prácticas es (1) analizar e indexar una colección de documentos, (2) buscar en la colección y (3) evaluar los resultados con base en un conjunto de criterios de relevancia. Trabajaremos con una colección moderna creada según el modelo TREC.

Se proporcionan algunas herramientas para el trabajo, pero se espera que las complete cuando sea necesario, como en cualquier proyecto real. Aparte del uso de Java y Lucene (Java), no hay tecnologías obligatorias. Si las proporcionadas no se ajustan a sus necesidades, se pueden reemplazar, pero el estudiante es responsable de su idoneidad y funcionamiento.

Resumen de TREC-Covid

TREC-COVID forma parte de la iniciativa TREC (Text Retrieval Conference), que organiza evaluaciones de sistemas de búsqueda impulsadas por la comunidad. El objetivo principal del reto fue ayudar a los investigadores a recuperar rápidamente artículos científicos relevantes sobre la COVID-19. Los participantes debían enviar resultados de búsqueda (runs) sobre diversos temas relacionados con la COVID-19, que fueron evaluados mediante juicios de relevancia por expertos.

Más información: [TRECVID website](https://trec-ovid.org/)

El conjunto de datos CORD-19

La colección de documentos utilizada es la COVID-19 Open Research Dataset(CORD-19), un repositorio de artículos de investigación sobre la COVID-19 y temas relacionados (por ejemplo, coronavirus, infecciones, epidemiología) que se actualiza constantemente.

Para esta tarea, **utilizamos la versión del 16 de julio de 2020**: (Enlace a todas las versiones de CORD-19: [CORD-19 Historical Releases](https://cord19.org/historical-releases/)) (Para la tarea, debe descargar la versión del 16 de julio de 2020!!). El conjunto de datos incluye publicaciones de múltiples fuentes, que comprenden artículos, informes y preprints: PubMed Central, bioRxiv y medRxiv. Esta versión se conoce como [TREC Covid Complete](https://cord19.org/trec-covid-complete/) y TREC proporciona también las consultas (topics) y juicios de relevancia para esas consultas.

Estructura del CORD-19 Dataset

El dataset CORD-19 tiene dos componentes principales_

1. Un archivo metadata.csv que contiene metadatos y la información principal.
2. El *full-text* de los artículos en archivos JSON .

Mas información el repositorio oficial en github:

<https://github.com/allenavi/cord19>

Estructura de Metadata.csv

El archivo metadata.csv contiene información importante para cada artículo, en particular:

-cord_uid: Identificador único del artículo.
-title: Título.
-authors: Lista de autores.
-abstract: Resumen del contenido.
-publish_time: Fecha de publicación.
-journal: Revista donde se publicó.
-doi: Digital Object Identifier, enlazando el artículo.
-url: Lista de urls asociadas con este artículo.
-license: Licencia.

Estos campos ayudan a identificar y recuperar artículos específicos de manera eficaz y eficiente.

Archivos JSON Full-Text

Cada documento puede incluir también una versión de texto completo en formato JSON (ubicada en la carpeta "document_parses"). El texto completo está estructurado y anotado como corresponde a un artículo científico:

Secciones estructuradas: El artículo se divide en secciones lógicas (p. ej., introducción, métodos, resultados, conclusión).

Figuras y tablas: Integradas en el artículo y referenciadas en el texto.

Citas: Referencias a otros artículos y fuentes.

Como trabaja TREC-COVID

Se crean (topics) temas de búsqueda (p. ej., "What is the role of remdesivir in treating COVID-19?"). Los participantes generan listas de documentos (*runs*) ordenadas por orden de importancia para cada tema utilizando sus sistemas de IR. Posteriormente, el NIST organiza una evaluación de relevancia de los documentos: expertos humanos, principalmente en el campo de la biomedicina, revisan y evalúan estos documentos en función de su relevancia para cada tema. Para poder hacerlo usa la técnica de *pooling*: se recogen los top-k primeros documentos de los rankings enviados por los sistemas participantes para cada consulta (*runs*), se eliminan los duplicados y se entregan a los revisores para la evaluación de relevancia. El valor de k depende del presupuesto (*budget*) para la evaluación. En TREC se han usado valores de k=50 pero también de k=100 o de k=10 (*shallow pool*).

Juicios de Relevancia (Relevance Judgments) y Evaluacion

Las evaluaciones humanas se traducen en juicios de relevancia (binarios o graduales). Los envíos de los sistemas participantes en TREC (runs) se puntúan según estos juicios, utilizando métricas como MAP, Recall, Precision y NDCG.

Search – Topics

Para procesar las diferentes consultas en el momento de la búsqueda, trabajaremos con el archivo "topics-rnd5.xml":

<https://ir.nist.gov/trec-covid/data/topics-rnd5.xml>

El archivo topics-rnd5.xml consta de 50 temas, con un elemento correspondiente a <query>:

```
<topics task="COVIDSearch 2020" batch="5">
<topic number="1">
<query>coronavirus origin</query>
<question>what is the origin of COVID-19</question>
<narrative>seeking range of information about the SARS-CoV-2 virus's origin, including its evolution, animal source, and first transmission into humans</narrative>
</topic>
<topic number="2">
<query>coronavirus response to weather changes</query>
<question>how does the coronavirus respond to changes in the weather</question>
<narrative>seeking range of information about the SARS-CoV-2 virus viability in different weather/climate conditions as well as information related to transmission of the virus in different climate conditions</narrative>
</topic>
<topic number="3">
<query>coronavirus immunity</query>
<question>will SARS-CoV2 infected people develop immunity? Is cross protection possible?</question>
<narrative>seeking studies of immunity developed due to infection with SARS-CoV2 or cross protection gained due to infection with other coronavirus types</narrative>
</topic>
...
<topic number="50">
<query>mRNA vaccine coronavirus</query>
<question>what is known about an mRNA vaccine for the SARS-CoV-2 virus?</question>
<narrative>Looking for studies specifically focusing on mRNA vaccines for COVID-19, including how mRNA vaccines work, why they are promising, and any results from actual clinical studies.</narrative>
</topic>
</topics>
```

Evaluacion – Qrels

Evaluaremos nuestros resultados utilizando el archivo qrels-covid_d5_j0.5-5.txt:

https://ir.nist.gov/trec-covid/data/qrels-covid_d5_j0.5-5.txt

Este archivo contiene la información de relevancia (1 o 2) y no relevancia (0) para los diferentes artículos identificados por "cord_uid".

Cada línea de archivo de juicios de relevancia ("qrels") contiene: topic-id iteration cord-id judgment

topic -id: el identificador de la consulta.

iteration: la versión del conjunto de datos (no importante).

cord-id: el identificador del documento.

judgment: donde el juicio es 0 para no relevante y 1/2 para relevante.

Práctica 1

Se debe indexar el conjunto completo de documentos. Un enfoque recomendado, dada la estructura de la colección, es: Analizar e indexar el contenido de los documentos obtenido del archivo de metadatos.

Analizar e indexar el contenido de los documentos con el texto completo de los artículos obtenido de los archivos JSON.

Para todo ello se puede y debe adaptar el código del ejemplo de películas y guiones.

Fecha límite: mitad de cuatrimestre. Se indicará la fecha concreta.

P1 – Primera tarea T1

Indexación. Debes indexar

Metadata.csv (campos **cord_uid**, **title**, **authors**, **abstract**, **publish_time**, **journal**, **doi**, **url**, **license**).

Campo **full-text** extraído de los archivos JSON files (pmc/pdf).

Detalles de la indexación:

- Hay cord_uid repetidos. Por tanto en la indexación debe producirse un índice con documentos con cord_uid únicos. El criterio para los repetidos será indexar sólo el primero que aparece por orden de fila en Metadata.csv.

- Para extraer el campo full-text es suficiente recoger el texto correspondiente a las claves text dentro del body_text. No es necesario parsear y extraer texto del título de secciones, ni de figuras, ni ninguna otra información. El campo full-text producido debe ser ese conjunto de párrafos separados por cambios de línea y que se corresponde con los valores de la clave text.

- Hay artículos que tienen archivos pdf json y pmc json. En ese caso debemos indexar sólo el pmc.

- Hay artículos que tiene más de un pdf/pmc json. En ese caso debemos indexar sólo el primero.

- Todos los campos deben permitir búsquedas.

- Todos los campos deben ser almacenados pero en el campo full-text debe existir la opción de que sea almacenado o no y debe compararse el tamaño del índice producido en función de esta opción.

- Los campos title, authors, abstract, full-text, deben almacenar vectores de términos para poder realizar la tarea 4 sobre ellos.

- Los campos deben ser tokenizados o no según su naturaleza.

- Además, Lucene permite convertir fechas en cadenas y viceversa (DateTools). De esta forma, las fechas se pueden usar en búsquedas. Esta parte es opcional, si no se hace las fechas deben recogerse como texto.

[Lucene Query Parser Syntax](#)

-El proceso de indexación debe ser concurrente. Es decir, varios hilos deben poder realizar la indexación, mejorando así la eficiencia. Debe estudiarse la eficiencia de la indexación con al menos 1, 4, 8 hilos, recogiendo los tiempos de indexación y comprobando que los índices producidos son funcionalmente equivalentes.

P1 – Tareas 2 y 3:

Búsqueda. Experimentaremos con un conjunto de consultas manuales (por ejemplo, *covid animal studies* o *how coronavirus affected Spain*). Debe:

T2. Usar el Query Parser y el buscador de Lucene para realizar la búsqueda según el campo específico. Es decir, el sistema debe permitir al usuario buscar en un campo concreto un contenido textual.

T3. Usar el MultiFieldQueryParser para buscar en varios campos con una o varias consultas, y en particular debe experimentar con la lógica para las cláusulas de la consulta.

En T2 y T3 tanto los campos como el texto de las consultas y la formulación de la consulta puede ser *hard coded*.

Para T2 y T3 debe producirse el listado ordenado por pantalla con información del cord_uid, título y score producido por el modelo de recuperación de información por defecto de Lucene.

P1 – Tareas 4 y 5.

Estadísticas del índice.

T4. Dado el identificador único de un documento (`cord_uid`) y un campo (`title`, `authors`, `abstract`, `full-text`), el sistema debe obtener los 10 mejores términos del documento en ese campo ordenados por `tf`, `idflog10` y `tf x idflog10`, informando en pantalla el `corduid`, título del documento, nombre del campo que se procesa y su contenido, número total de términos para ese campo de ese documento, términos ordenados y las estadísticas que producen el orden.

T5. Dado un campo cualquiera, el sistema debe mostrar por pantalla el número total de términos para ese campo y mostrar los 10 más específicos (`df` más bajo) y los 10 con menos ocurrencias en la colección (*total term frequency* o *collection frequency*) junto con los valores de esas estadísticas. También debe mostrar los 10 menos específicos (`df` más alto) y los 10 con mas ocurrencias en la colección (*total term frequency* o *collection frequency*) junto con los valores de esas estadísticas.

Entrega P1.

Debe subir el código de su proyecto a su repositorio y un archivo README (texto plano o md) con las instrucciones de ejecución de cada clase principal. Las rutas de datos e índice, y los parámetros que sean posible deben darse por la línea comando para facilitar la ejecución por terceros. No suba los datos ni los índices producidos. El repositorio es sólo para código o archivos de configuración o similares.

Para esta práctica todas las pruebas se harán con el Standard Analyzer y con el modelo de RI por defecto de la versión de Lucene que se está usando.

Se fijará una fecha límite para la primera práctica, alrededor de la mitad de curso. La evaluación consistirá en la defensa del código, de su ejecución y de los resultados, la realización de ejercicios que impliquen codificación de variantes y una evaluación general del código. La evaluación del código se basará tanto en el cumplimiento de los requisitos como en la calidad del proyecto, incluyendo su eficiencia.

Práctica 2 – T1 (Search) La colección incluye un conjunto de 50 *topics* (consultas) y su respectivo conjunto de juicios de relevancia. Debe utilizar los *topics* indicados para buscar en la colección y evaluar la calidad de sus resultados.

Para la búsqueda, deberá:

- Analizar el archivo de *topics* (necesitará un analizador XML).

- Buscar mediante el *query topic* : <https://ir.nist.gov/trec-covid/data/topics-md5.xml>

- Generar una lista de resultados por cada *topic*. El archivo generado debe ser un archivo ".txt" que siga el formato tradicional de envío de TREC (*runs*). Más información sobre el formato en la página de definición de la tarea de recopilación:

<https://ir.nist.gov/trec-covid/round1.html>

- Generar un *ranking* de 100 documentos por *query*

Para la búsqueda debe tener un índice correcto indexado con la opción LMJelinekMercerSimilarity para el IndexWriterConfig y el StandardAnalyzer, ya que buscaremos con este modelo de búsqueda y parsearemos las *queries* con ese analizador. Al IndexSearcher también hay que indicarle este modelo de búsqueda y el parámetro lambda.

La búsqueda debe tener las siguientes opciones:

- el campo a buscar: title, abstract o full-text

- el rango de *queries* a buscar de entre el rango máximo de 50 posibles, por ejemplo, 1-50, 5-5 o 10-29

- el parámetro lambda con un valor entre: 0.01, 0.1, 0.3, ..., 0.9, 1.0 para especificar el modelo de búsqueda

El fichero .txt de resultados debe tener una primera línea identificando el campo, rango de *queries* y lambda.

Práctica 2 – T2 (Eval) :

Una vez realizada una búsqueda con las opciones de T1, deben evaluarse los resultados de la búsqueda con las métricas:

P@10, R@10, MAP@10, [MAP@100](#), [NDCG@10](#), [NDCG@100](#)

Existen varias versiones de NDCG. Debe usarse la de la sección 8.4.3 del libro de Crof et al.

El fichero con los *qrels* está disponible en: https://ir.nist.gov/trec-covid/data/qrels-covid_d5_j0.5-5.txt

El formato de las columnas es el standard de TREC: https://trec.nist.gov/data/qrels_eng/

Práctica 2 – T3 (BestValues) : En esta tarea deben obtenerse los mejores valores para los 50 *topics* y cada campo title, abstract o full-text, y las métricas [MAP@100](#) y [NDCG@100](#). Incluir los resultados de las métricas para cada campo con los mejores valores de lambda que llevan a esos resultados óptimos, de forma clara y legible al final del README.

Práctica 2 – T4 (RankQueries): Dado un rango de *queries* y una métrica de las enumeradas en T2 debe ordenar las *queries* por dificultad, es decir, en orden creciente de dificultad y mostrar el valor de la métrica.

Práctica 2 – T5 (MetricCorrelation): Dado un rango de *queries* y las métricas enumeradas en T2 debe ordenar las *queries* por dificultad y obtener el coeficiente de correlación de Kendall tau-b que puede encontrar en Apache Commons Math. Para el caso de las 50 *queries* debe mostrar el resultado de forma clara y legible al final del README.

Cada una de las tareas de la práctica 2 debe poder ejecutarse independientemente, es decir, debe tener una clase principal.

Las clases de Java Scanner y PrintWriter son las más sencillas para leer y escribir ficheros de texto para las necesidades de esta práctica. Se dejó un código en el campus virtual para parsear el archivo de *topics*.

Se indicará el día de defensa. Las normas de subida y de evaluación son similares a las de P1.